

RESUMEN

Esta monografía presenta una revisión sistemática de las técnicas de *fine-tuning* para *Large Language Models* (LLMs) publicadas entre 2020 y 2025, conducida mediante el protocolo PRISMA 2020. A partir de una búsqueda inicial de 140 registros en Scopus, se seleccionaron 84 estudios empíricos con evaluación cuantitativa, distribuidos en cuatro dominios de aplicación: Salud y Biomedicina (35,7 %), Lenguaje y Humanidades (25,0 %), Ciencias Exactas y Computación (23,8 %) e Industria y Negocios (15,5 %). El análisis abarcó nueve técnicas representativas organizadas en tres paradigmas: *Full Fine-Tuning* y SFT como enfoques de actualización completa de parámetros, cinco métodos de *Parameter-Efficient Fine-Tuning* (LoRA, QLoRA, *Adapter Layers*, *Prefix Tuning*, *Prompt Tuning*) y dos métodos de alineación (RLHF, DPO). Los resultados evidencian la hegemonía de LoRA y sus variantes (incluyendo QLoRA), presente en el 79,8 % de los estudios incluidos, con una tendencia creciente hacia su combinación con mecanismos complementarios según el dominio operativo. La calidad metodológica del corpus fue aceptable, con un *score* promedio de 2,61 sobre 3,0. Se identificaron tres patrones transversales: la ventaja del *fine-tuning* específico sobre modelos de mayor escala sin adaptación, la efectividad de técnicas PEFT en lenguas y dominios de baja cobertura, y la tendencia hacia arquitecturas compuestas en aplicaciones de producción.

Palabras clave: *fine-tuning*, *Large Language Models*, LoRA, *Parameter-Efficient Fine-Tuning*, RLHF, DPO, revisión sistemática, PRISMA, procesamiento de lenguaje natural, evaluación empírica.

DESARROLLO

1. Introducción


El rendimiento de los LLMs en dominios específicos depende en gran medida de la técnica de *fine-tuning* empleada para adaptarlos. Esta revisión sistematiza la evidencia empírica sobre nueve técnicas representativas organizadas en tres paradigmas: *Full Fine-Tuning* y su variante *Supervised Fine-Tuning* (SFT), que actualizan la totalidad de los parámetros del modelo; cinco métodos PEFT (LoRA, QLoRA, *Adapter Layers*, *Prefix Tuning*, *Prompt Tuning*), que entrenan solo un subconjunto reducido de parámetros; y dos métodos de alineación (RLHF, DPO), que ajustan el comportamiento del modelo según preferencias humanas. El análisis identifica patrones de aplicabilidad de estas técnicas por dominio.

Pregunta de investigación:

¿Cuáles son las características, el rendimiento reportado en distintos dominios de aplicación, y los patrones de aplicabilidad de las técnicas de *fine-tuning* para *Large Language Models* desarrolladas entre 2020 y 2025, según la evidencia reportada en la literatura académica?

2. Metodología PRISMA


La búsqueda se realizó en Scopus con criterios de selección centrados en la calidad del diseño experimental: presencia de *split* de evaluación, *baseline* de comparación, reporte de *hyperparameters* y descripción del *dataset*.



3. Distribución del corpus por dominio

La clasificación por dominio se realizó mediante el proceso de evaluación de calidad metodológica (*quality assessment*), a partir del texto completo de cada artículo. Salud y Biomedicina concentra el mayor volumen, reflejo de la alta demanda de modelos especializados en texto clínico y biomédico.

Número de estudios incluidos por dominio de aplicación



Nota. Elaboración propia a partir del corpus de 84 estudios incluidos.

4. Dominancia de LoRA por dominio

LoRA y sus variantes (incluyendo QLoRA) están presentes en el **79,8 % de los estudios** incluidos (67 de 84). Su adopción es transversal a los cuatro dominios, con presencia mayoritaria incluso en dominios de alta especialización como Salud y Biomedicina.

CONCLUSIONES


- LoRA como método dominante.** LoRA y sus variantes son el método dominante de adaptación, presentes en el 79,8 % de los estudios (67 de 84), con adopción transversal a todos los dominios y una concentración que crece desde Salud y Biomedicina (70,0 %) hasta Industria y Negocios (100,0 %). La tendencia es hacia configuraciones híbridas (LoRA + RLHF, LoRA + RAG) en aplicaciones de producción, lo que sugiere que la comunidad investigadora ha convergido hacia un conjunto acotado de configuraciones efectivas.
- Mejoras consistentes del fine-tuning paramétrico eficiente.** De los 30 estudios con pares de valores comparables, 29 reportan mejora sobre el *baseline*, con ganancias relativas que en varios casos superan el 100 %. Las ganancias más pronunciadas se concentran en escenarios de especialización lingüística y dominios poco representados en el preentrenamiento, donde modelos de tamaño moderado compiten con modelos propietarios de mayor escala.
- Criterios de selección según contexto operativo.** Ante datos sensibles o restricciones de privacidad, QLoRA sobre modelo abierto; ante dominios especializados o lenguas de baja cobertura en el preentrenamiento, LoRA con datos del dominio; ante requisitos de alineación en producción, la combinación LoRA + RLHF es la configuración predominante en la literatura reciente. La selección no depende solo del rendimiento absoluto, sino también de factores contextuales como privacidad y recursos lingüísticos disponibles.

REFERENCIAS

- Ding, N., Qin, Y., Yang, G., Wei, F., Yang, Z., Su, Y., Hu, S., Chen, Y., Chan, C.-M., Chen, W., Yi, J., Zhao, W., Wang, X., Liu, Z., Zheng, H.-T., Chen, J., Liu, Y., Tang, J., Li, J. y Sun, M. (2023). Parameter-efficient fine-tuning of large-scale pre-trained language models. *Nature Machine Intelligence*, 5(3), 220-235. <https://doi.org/10.1038/s42256-023-00626-4>
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. y Chen, W. (2021). LoRA: Low-Rank Adaptation of Large Language Models. <https://arxiv.org/abs/2106.09685>
- Lialin, V., Deshpande, V., Yao, X. y Rumshisky, A. (2024). Scaling Down to Scale Up: A Guide to Parameter-Efficient Fine-Tuning. <https://arxiv.org/abs/2303.15647>
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J. y Lowe, R. (2022). Training language models to follow instructions with human feedback. <https://arxiv.org/abs/2203.02155>
- Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... y Moher, D. (2021). Declaración PRISMA 2020: una guía actualizada para la publicación de revisiones sistemáticas. *Revista Española de Cardiología*, 74(9), 790-799. <https://doi.org/10.1016/j.recsep.2021.06.016>
- Rafailov, R., Sharma, A., Mitchell, E., Manning, C. D., Ermon, S. y Finn, C. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *Thirty-seventh Conference on Neural Information Processing Systems*. <https://openreview.net/forum?id=HPuSiXJaa9>

La figura siguiente muestra la distribución por técnica específica en cada dominio, confirmando la hegemonía de LoRA incluso al desagregar por método.


Distribución de técnicas de *fine-tuning* por dominio de aplicación



Nota. Elaboración propia a partir del corpus de 84 estudios incluidos.

5. Patrones transversales

Dirección de la mejora respecto al *baseline* por dominio (n = 30)



Nota. Elaboración propia. Subconjunto de 30 estudios con *baseline* fijo y resultado numérico comparable; 29 de 30 reportan mejora positiva, con el único resultado negativo en Ciencias Exactas y Computación.

- El *fine-tuning* específico supera al modelo base preentrenado sin adaptación de dominio en la mayoría de los estudios evaluados.
- Las técnicas PEFT son especialmente efectivas en lenguas y dominios de baja cobertura en el preentrenamiento, donde modelos de tamaño moderado compiten con modelos propietarios de mayor escala en configuración *zero-shot*.
- En aplicaciones de producción, LoRA tiende a combinarse con mecanismos complementarios (RLHF, RAG, aprendizaje federado) según el dominio operativo.